Търсене и извличане на информация.
Приложение на дълбоко машинно обучение

Зимен семестър 2021/2022

Задание за курсов проект
Невронен машинен превод

24 януари 2022 г.

Общ преглед

За курсовия проект ще трябва да реализирате невронен машинен превод с техники за дълбоко машинно обучение. Проектът е планиран така, че да ви даде възможност бързо да се задълбочите в експерименти с дълбоко машинно обучение. В рамките на проекта ще имате възможност да имплементирате съвременни техники и да експериментирате със собствени нови архитектури.

Задача: Невронен машинен превод с рекурентна невронна мрежа от английски към български език

В машинния превод нашата целта е да преведем изречение от входния език (английски) в целевия език (български). В това задание се изисква да се имплементира архитектура за конкретния "последователност към последователност" (Seq2Seq) проблем, т.е. да се реализира система за невронен машинен превод. Силно препоръчително е архитектурата да включва и механизъм за "внимание" (Attention). На фигура 1 е представена схема на примерна архитектура за осъществяване на невронен машинен превод. На фигура 2 е представена примерна обобщена схема

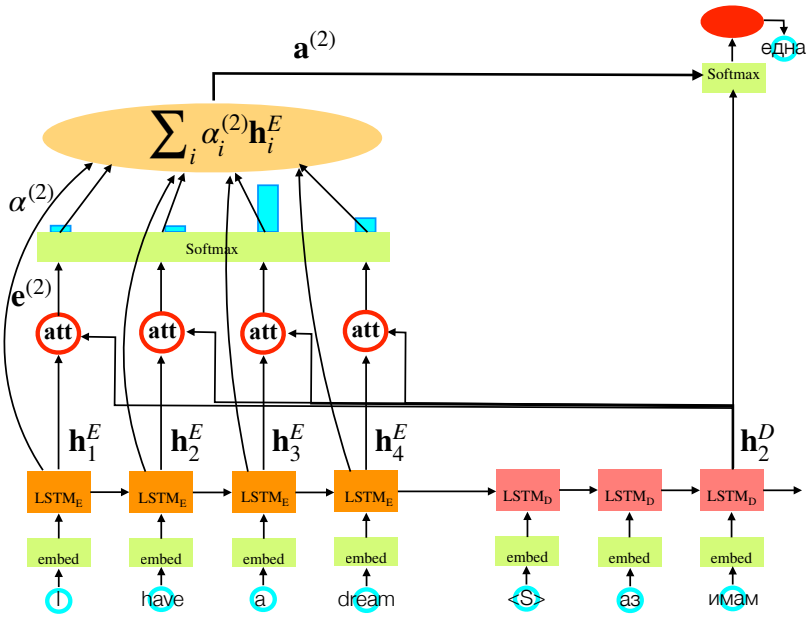

Фигура 1: Схема на примерна рекурентна невронна мрежа с механизъм за внимание за машинен превод.

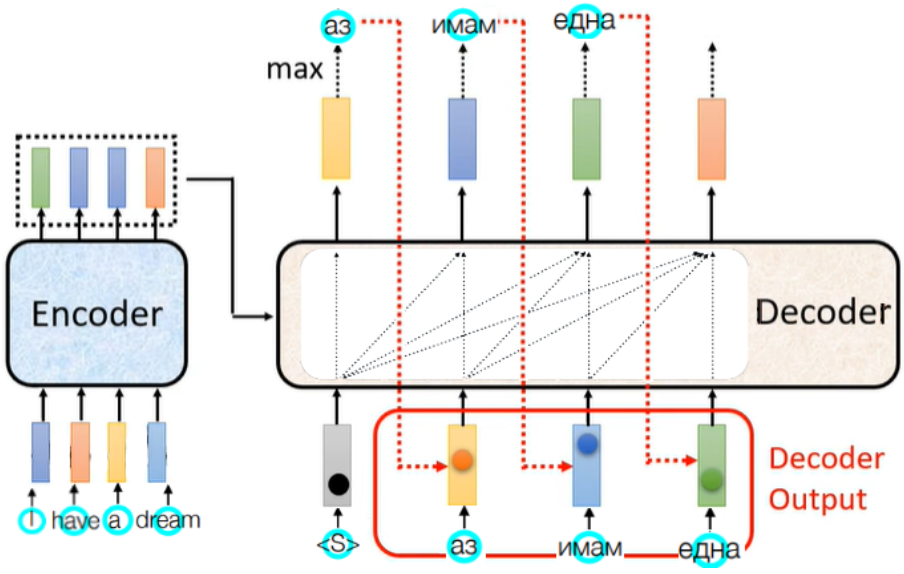

Фигура 2: Обобщена схема на архитектура за машинен превод, съвместима и с архитектурата Transformer.

за осъществяване на невронен машинен превод, неин частен случай е и архитекрурата Transformer.

Изискване за съдържание на курсовата работа

Курсовата работа трябва да съдържа:

1. Всички програмни модули и параметри, с които е имплементирана вашата невронна мрежа.

2. Програмите за подготовка на данни, обучение и тестване на решението, ако са различни от съответните помощни програми, включени в пакета.

3. Обучен модел на вашата реализация, който достига докладваното от вас качество на превода.

4. Програма позволяваща превод на произволен корпус от изречения на входния език и записването на резултата в нов файл, ако е различна от съответната помощна програма, включена в пакета.

5. Кратко описание / доклад – в рамките на 2-3 страници – на вашето решение. Описанието следва да съдържа:

   (а) Вашите имена и факултетен номер.

   (б) Достатъчно пълно описание на архитектурата, която сте реализирали. Описанието на архитектурата следва да съдържа и параметрите, които сте използвали, така че описанието да е достатъчно за репродуцирането й.

   (в) Цитирания и референции към всички чужди програми и източниците на информация, които сте използвали.

   (г) Описание за начина на обучение на модела и проведените експерименти за настройване на параметрите за обучение.

   (д) Резултат от оценяване на модела върху тестовия корпус – перплексия и BLEU резултат.

Ограничения и препоръки за архитектурата на модела

Цел на курсовата работа е от една страна да даде възможно най-голяма свобода и креативност за реализирането на модела. От друга страна се цели да постави някакви рамки по отношение на платформата и методологията, за да се поставят студентите при близки условия.

Ограничения и изисквания

- Моделът трябва да е имплементиран с използване на платформата `Pytorch`.
- Моделът трябва да използва архитектура encoder-decoder, като модулите encoder и decoder трябва да бъдат реализирани с рекурентни невронни мрежи или с Transformer блокове [Vaswani and al.(2017)].
- За обучението на модела не се разрешава използването на други корпуси, извън приложения в пакета (вижте раздела Корпус).
- Предадената имплементация трябва да реализира възможност за превод на корпус на изречения. Това може да стане като се използва функционалността `translate` на приложената програма `run.py` (вижте раздела Помощни програми). Но е допустима и друга имплементация, която трябва да е добре описана.

Препоръки

Дадените по-долу препоръки са само за ориентация. В никакъв случай няма изискване за реализация на коя да е от тях. Също така, имате пълната свобода да реализирате други елементи към вашата архитектура, които не са описани по-долу, стига да не противоречат на описаните в предишния раздел ограничения и изисквания.

- Препоръчително е да се започне с по-проста архитектура, която евентуално да се усложнява, ако не дава желаните резултати.
- Реализацията на търсене по лъча не е задължително. Обикновено алчното търсене дава 1-2 точки по-нисък BLEU резултат.
- Влагането на думите може да бъде реализирано както по обичайния начин със слой за влагане, така и чрез конволюция на символно ниво, както беше показано на последното упражнение.
- За да може де се предвиждат целеви думи, които не са в речника на целевия език може да се добави допълнителна невронна мрежа на ниво символи, както е показано в статията [Luong and Manning(2016)].

В случай, че изберете подход с рекурентни невронни мрежи:

- Реализирането на архитектура с "внимание" не е задължително, но е силно препоръчително. Без механизъм за "внимание" качеството на превода ще бъде значително по-ниско. Подобна архитектура е описана в [Bahdanau et al.(2015)Bahdanau, Cho, and Bengio] и [Britz et al.(2017)Britz, Goldie, Luong, and Le].

- Векторът за внимание е добре да се добави след рекурентния слой (late binding) или едновременно след рекурентния слой и заедно със съответната нова входна дума към рекурентната клетка (early+late binding). Може да се добави и при входа на декодера (initial binding).

- В статията [Britz et al.(2017)Britz, Goldie, Luong, and Le] е изследвано влиянието на различните параметри върху качеството на превода. За да спестите време за обхватни експерименти е препоръчително да се запознаете с тази работа.

- При енкодера обикновено се получават по-добри резултати при използване на двупосочна рекурентна невронна мрежа.

- Добавянето на допълнителен линеен слой с нелинейност след прибавянето на вектора за внимание към скрития вектор на рекурентната невронна мрежа обикновено подобрява качеството на превода.

Насърчаваме ви да подходите към проблема и с архитектури, основани на Transformer. Следните препоръки в тази насока могат да са ви от полза:

- Запознайте се подробно с архитектурата описана в статията Attention is All you Need. [Vaswani and al.(2017)].

- Опитайте да имплементирате нужните модули без да ползвате чужди имплементации. Библиотеката Pytorch предоставя готов клас Transformer. Ако го използвате (както и ако копирате предоставения към него изходен код), работата ви ще получи значително по-малко точки по критерии оригиналност и самостоятелна имплементация.

- Горното условие важи и за изграждащи компоненти, които също са предоставени като готови класове: TransformerEncoder, TransformerEncoderLayer, TransformerDecoder, TransformerDecoderLayer. Използването им ще доведе до намаляне на оценката за оригиналност.

Корпус

В пакета на заданието в директорията `en_bg_data` е предоставен двуезичен английско-български подравнен корпус. Корпусът се състои от:

- 180000 двойки изречения за обучение във файловете `train.en` и `train.bg`.
- 1000 двойки изречения за валидация във файловете `dev.en` и `dev.bg`.
- 6000 двойки изречения за тестване във файловете `test.en` и `test.bg`.

Помощни програми

В пакета са включени помощни програми, които свободно може да използвате във вашата курсова работа. Използването на тези програми не е задължително. Вие може да ги променяте свободно или да ги заменяте с други по ваше усмотрение.

`model.py`

Ако искате да ползвате пълната функционалност на приложените помощни програми е необходимо във файла `model.py` да имплементирате модел за машинен превод в обект `NMTmodel`, който да имплементира следните методи:

- `__init__(self, ...)` – конструктор на обекта,
- `forward(self, source, target)` – метода трябва по партида от входни изречения `source` и съответна партида от изходни изречения `target` да върне съответната крос-ентропия,
- `translateSentence(self, sentence)` – метода трябва да извършва превод на даденото изречение `sentence` от входния към целевия език.

`utils.py`

Във файла `utils.py` са имплементирани функциите за подготовка на тренировачни данни. В този файл са имплементирани следните функции и обекти:

- Обект `progressBar` – обект за визуализиране на прогрес.

- Функция `readCorpus(fileName)` – функцията чете текстов файл от изречения разделени с нов ред и връща списък от изречения, като всяко изречение е списък от думи.
- Функция `getDictionary(corpus, startToken, endToken, unkToken, padToken, wordCountThreshold = 2)` – от даден корпус извлича всички думи и връща речник на думите с повече от зададения брой срещания във вид на хеш, който връща индекса на съответната дума. Към речника се добавят думи за начало, край, непозната дума и попълване.
- Функция `prepareData(sourceFileName, targetFileName, sourceDevFileName, targetDevFileName, startToken, endToken, unkToken, padToken)` – подготвя данните необходими за трениране.

`run.py`

Във файла `run.py` са имплементирани функционалности за трениране, прилагане и тестване на модел. Очаква се във файла `model.py` да създадете своя имплементация на модел за невронен машинен превод. Програмата `run.py` използва файла `parameters.py`, в който се прочитат параметрите, необходими за изпълнение на съответните функционалности. В `run.py` са имплементирани следните команди:

- `python run.py prepare` – подготвя данните като изчита съответните корпуси и записва на диска необходимите python обекти.
- `python run.py train` – извършва първоначален процес на обучение на модел. Предполага се, че в `model.py` е имплементиран модел `NMTmodel`, който реализира невронен машинен превод и неговият `forward` метод по партиди от входни и целеви изречения връща съответната крос-ентропия. По време на обучението, през `test_every` брой стъпки се измерва крос-ентропията спрямо корпуса за верификация. Ако стойността е по-ниска, то модела се запазва на диска. Ако след `max_patience` брой опити не се подобри крос-ентропията, то се намалява `learning_rate` с фактор `learning_rate_decay` и се продължава обучението с по-малкия `learning_rate`. След `max_trials` брой намалявания на `learning_rate` обучението се прекъсва преждевременно.
- `python run.py extratrain` – извършва допълнителен цикъл на трениране върху последно записания модел. Тази команда позволява да се продължи обучението след прекъсване на обучението.

- `python run.py perplexity <sourceCorpus> <targetCorpus>` – измерва перплексията на вече записан модел върху тестов корпус с входни изречения дадени във файла `<sourceCorpus>` и целеви изречения дадени във файла `<targetCorpus>`.

- `python run.py translate <sourceCorpus> <resultCorpus>` – превежда тестов корпус с входни изречения дадени във файла `<sourceCorpus>` в целеви изречения. Целевите изречения се записват във файла `<resultCorpus>`. За да работи тази команда трябва в модела `NMTmodel` да бъде имплементиран метод `translateSentence(self, sentence)` за превод на единично изречение.

- `python run.py bleu <targetCorpus> <resultCorpus>` – измерва BLEU точките между корпус от целеви изречения преведени от референтен преводач дадени във файла `<targetCorpus>` и корпус от целеви изречения получени от машинния превод дадени във файла `<resultCorpus>`.

Използване на чужди програми извън Pytorch

1. Вие имате право да използвате всякакви съществуващи програми и библиотеки извън стандартния Pytorch пакет. Трябва обаче **ясно да цитирате** свойте източници и да посочите кои части от проекта не са ваша работа. Ако използвате или заемате код от която и да е външна библиотека, опишете как използвате външния код и предоставете връзка към източника. Вашата курсова работа ще бъде оценена според вашите приноси – това, което сте добавили върху работата на другите.

2. Вие можете свободно да обсъждате идеи и подробности за курсовата работа с други студенти. При никакви обстоятелства обаче не е разрешено да разглеждате кода на другите или да включвате техния код във вашия проект.

3. Вие нямате право да споделяте кода си публично (например в GitHub), преди курсът да е приключил.

Забележки

1. За курсовата работа не се предоставя код за тестване. Препоръчва се вие сами да си направите тестови скриптове, с които да се уверите в коректността на програмите ви.

2. Очаква се най-много време да ви отнеме експериментирането с настройка на параметрите на вашия модел. Един пълен цикъл на обучение отнема няколко часа. Поради това е необходимо да си планирате добре времето, така че да успеете да се справите навреме с работата.

3. За обучението на модела ще ви бъде необходимо значително машинно време. Ако не разполагате с мощен компютър с графична карта може да се възползвате от услугата Google Colab `https://colab.research.google.com`, където безплатно се предоставя изчислителна среда с инсталирани Python и Pytorch, която може да се конфигурира да използва графична карта (GPU).

Критерии за оценяване

Курсовият проект ще бъде оценен цялостно. Това означава, че ще бъдат разгледани различни фактори при определяне на оценката: креативността, сложността и техническата коректност на вашата реализация, вашия конкретен принос, качеството на превода на вашия модел, усилията, които сте приложили, и качеството на вашето описание.

За да се оцени достигнатото качество на превод ще бъде използвана програмата за измерване на BLEU, която е приложена в пакета на заданието. Измерването ще бъде извършено върху тестов корпус от текстове от европейския парламент, който не е приложен към материалите. Добрите реализации се очаква да достигнат BLEU резултат в рамките на около 35-42 точки.

Важно: Постигнатият BLEU резултат е само един от критериите за определяне на оценката. Останалите критерии, дадени по-горе, имат не по-малко значение. Например, оригинална, самостоятелно имплементирана система, която достига 36 точки би могла да бъде оценена по-високо от реализация, достигаща 41 точки, чиито код почти изцяло е взаимстван от публикувана чужда система.

Инструкция за предаване на курсовата работа

Изисква се в Moodle да бъде предаден архив FNXXX.zip (където XXX е вашият факултетен номер), в който са пакетирани всички файлове от изисканото съдържание.

Пожелаваме ви успех!

Литература

[Vaswani and al.(2017)] Ashish Vaswani and al. Attention is all you need. In *Proceedings of the 31st International Conference on Neural Information Processing Systems*, pages 6000–6010. Association for Computational Linguistics, December 2017. doi: 10.5555/3295222.3295349. URL `https://dl.acm.org/doi/10.5555/3295222.3295349`.

[Luong and Manning(2016)] Minh-Thang Luong and Christopher D. Manning. Achieving open vocabulary neural machine translation with hybrid word-character models. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1054–1063, Berlin, Germany, August 2016. Association for Computational Linguistics. doi: 10.18653/v1/P16-1100. URL `https://www.aclweb.org/anthology/P16-1100`.

[Bahdanau et al.(2015)Bahdanau, Cho, and Bengio] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. In Yoshua Bengio and Yann LeCun, editors, *3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings*, 2015. URL `http://arxiv.org/abs/1409.0473`.

[Britz et al.(2017)Britz, Goldie, Luong, and Le] Denny Britz, Anna Goldie, Minh-Thang Luong, and Quoc Le. Massive exploration of neural machine translation architectures. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 1442–1451, Copenhagen, Denmark, September 2017. Association for Computational Linguistics. doi: 10.18653/v1/D17-1151. URL `https://www.aclweb.org/anthology/D17-1151`.